Version for proposal

This project studies whether AI-related corporate disclosure is a form of economically meaningful soft information, and whether a transparent NLP-based framework can distinguish substantive AI disclosure from generic AI talk.

The central idea is that not all AI-related disclosure is equally informative. Some disclosures reflect genuine technological implementation, operational change, and firm transformation, while others may primarily represent broad rhetoric, symbolic positioning, or market hype.

More specifically, the project asks three questions:

RQ1. Can a transparent NLP-based framework identify AI-related disclosure in firms' 10-K filings and distinguish substantive AI disclosure from generic AI statements?

RQ2. Is substantive AI disclosure more closely associated with firm characteristics consistent with technological transformation and operational implementation than generic AI talk?

看document_ai_intensity和company盈利能力的关系：

1. 只要2025年的ai_intensity即可，我们需要2024-2025年的stock price growth
2. Ai_intensity作为continuous variable
   substantive/generic作为dummy variable
   → 看如果两个公司一个是substantive，一个是generic，有相同的ai intensity，那么substantive的growth会比generic的growth高多少
3. Control variable?

RQ3. After controlling for conventional financial variables, does substantive AI disclosure provide incremental explanatory power for firm value and future fundamentals, and does this informational relevance become stronger in the post-ChatGPT / post-GenAI-boom period?

The original sample contains 50 company-year MD&A documents from 7 firms over 2018–2025. We first apply an AI keyword filter and retain only those MD&A documents with at least one AI-related keyword hit for further classification. As a result, the final classification dataset contains 13 company-year observations. Importantly, the 37 excluded observations are not labeled as non-AI-related disclosures; rather, they are excluded because they do not match the current AI keyword list.

At the document level, we construct a binary variable, `SubstantiveDisclosure`, equal to 1 if the MD&A is classified as substantive and 0 if classified as generic. We also use `document_ai_intensity` as a continuous measure of AI disclosure intensity.

In addition, we construct six dummy variables for substantive disclosure subcategories: product development, AI product/provider, pricing optimization, inventory management, operational

efficiency, and AI risk disclosure. For documents with AI risk disclosure, we further classify risk-related content into six finer categories: regulatory risk, operational risk, competitive risk, cybersecurity risk, ethical risk, and third-party risk.

？:

```
ai_keyword_hit
substantive_disclosure
ai_disclosure_intensity
subcat_product_development
subcat_ai_product_provider
subcat_pricing_optimization
subcat_inventory_management
subcat_operational_efficiency
subcat_ai_risk_disclosure
risk_regulatory
risk_operational
risk_competitive
risk_cybersecurity
risk_ethical
risk_third_party
```

log(Assets)：公司规模
ROA：盈利能力
Leverage：杠杆
SalesGrowth：成长性
R&D/Assets：研发强度
Capex/Assets：资本开支强度
Intangibles/Assets：无形资产强度
Industry FE
Year FE
Tobin’s Q

A组：Data Cleaning

不负责判断 generic/substantive，把原始 10-K 变成干净、可分析的 **MD&A** 句子级数据。

1. 抽取 **MD&A**
    - 从 10-K 里准确截取 Item 7（MD&A）
    - 结束边界设在 Item 7A 或 Item 8
    - 去掉目录里伪出现的标题，避免前后 section 混进去

2. 清洗文本
    - 去 HTML/XBRL tags
    - 去页眉页脚、table 残片、导航字符串、乱码
    - 统一小写、空格和换行
    - 保留否定词、情态词、数字，不要过度清洗
3. 句子切分
    - 把 MD&A 切成 sentence-level
    - 注意 10-K 长句、分号、broken lines，不能简单按句号切
4. 去重和质量控制
    - 去 exact duplicates
    - 去 near duplicates
    - 删除标题句、残句、太短句
5. 可选：初筛 **AI candidate**
    - 用 seed dictionary 标记包含 AI 相关词的句子，供 B组进一步分类
    - 目标是高召回，不要求高精度

A组最终交付一个 **sentence-level MD&A master file**，至少包含：

- cik / gvkey / ticker / company / filing_date / fiscal_year
- sentence_id / sentence_order
- sentence_raw / sentence_clean
- mdna_total_word_count / mdna_total_sentence_count
- ai_candidate_flag / ai_keyword_matched_terms
- is_exact_duplicate / is_near_duplicate / keep_sentence_flag

在完成 MD&A 提取后，对原始文本进行清洗与标准化。清洗过程主要包括：

- 删除 HTML / XBRL tags
- 删除页眉页脚、表格残片、导航字符串
- 删除编码噪音与无意义特殊符号
- 统一多余空格、换行与格式断裂
- 剔除不构成完整句子的交叉引用碎片

在文本标准化过程中，采用 lowercase conversion 和 whitespace standardization，但不进行过度清洗。特别是：

- 保留否定词与情态词（如 may, could, expect, plan）
- 保留数字与百分比信息
- 不删除所有 stop words
- 不进行激进 stemming

这样做的原因是，后续 generic 与 substantive 的区分依赖于句子语义、实施状态、管理层语气与 firm-specific linkage，而不仅仅是关键词出现频率。

句子切分

在清洗后的 MD&A 文本基础上，将文本切分为 **sentence-level observations**。句子是本项目的主要分析单位，原因在于：

- 同一段落中往往同时包含 broad strategic language 和 concrete operational detail
- 若以段落为单位，generic 与 substantive 信息容易混合，造成分类噪音
- 句子级分析更适合后续精细分类与聚合

句子切分需要适应 10-K 的文本特征，包括长句、分号、括号、项目符号残留与 broken lines 等。不能简单按句号分割，而应结合规则化 tokenizer 与人工检查逻辑。

去重与质量控制

为了避免 boilerplate language 或格式重复导致披露强度被高估，在 sentence-level 数据构建阶段应加入以下质量控制：

- 去除 exact duplicate sentences
- 去除 near-duplicate sentences
- 删除标题句、残句和过短句
- 删除不构成完整语义单位的 observation

Data Cleaning 阶段输出

Data Cleaning 组的最终输出应为一个 **sentence-level MD&A master file**，其中每一行对应一个 firm-year MD&A 中的一句话，包含以下核心字段：

firm-year identifiers

- `cik`
- `gvkey`
- `ticker`
- `company_name`
- `filing_date`
- `fiscal_year`
- `accession_number`

MD&A metadata

- `section_name`
- `mdna_total_word_count`
- `mdna_total_sentence_count`
- `mdna_total_char_count`

sentence-level fields

- `sentence_id`
- `sentence_order`
- `sentence_raw`
- `sentence_clean`
- `sentence_word_count`

quality flags

- `is_exact_duplicate`
- `is_near_duplicate`
- `keep_sentence_flag`

AI candidate support

- `ai_candidate_flag`
- `ai_keyword_matched_terms`

B组：NLP

在 A组给的 sentence-level 数据上做**AI disclosure** 分类，然后聚合成回归可用变量。

分成 4 类：

- `0 = not_meaningful_ai_mention`
- `1 = generic_ai_disclosure`
- `2 = substantive_ai_implementation`
- `3 = substantive_ai_risk_governance`

not meaningful AI mention

- 只是提到 AI 词
- 标题、法规名、broad list、顺带提 AI
- 没有真正披露内容

generic

- 提到 AI，但只是战略方向、趋势、机会、探索
- 没有具体 use case、deployment、业务对象、风险机制

substantive implementation

- 公司自己把 AI 用到产品、服务、流程、内部运营
- 有 deploy / integrate / launch / automate / build 之类动作
- 有 firm-specific use case

substantive risk/governance

- 公司自己实际使用 AI 后，披露 model review / testing / validation / governance
- 或具体 AI 风险机制，比如 AI-enabled cyber risk、model failure 等

1. 不要把 `final_disclosure_type` 当主变量
    - 文档里可能既有 generic 又有 substantive
    - 后面做回归要用 continuous measures，不要只靠一个 final label
2. 加上 `not_meaningful_ai_mention`
    - 现在很多 broad mention 被算进了 disclosure，会把 measure 搞脏
3. 把 **substantive** 拆成 **implementation** 和 **risk/governance**
    - 两类经济含义不一样，后面回归也可以分别看
4. 监管提到具体功能 **≠ substantive**
    - 比如提 underwriting / claims / marketing，如果只是说 regulator 关注这些领域，不算公司自己的 substantive AI use
5. 做 **sentence** 去重
    - 现在 sample 里有重复/近重复 summary，会虚高 hit counts

1. 先用 seed lexicon 筛 AI candidate sentences
2. 写 annotation codebook
3. 人工标 300–500 句做 calibration
4. 扩大到 1000–2000 句做训练集
5. 先做 rule-based baseline
6. 再做 supervised classifier
    - TF-IDF + logistic / SVM
    - SBERT / FinBERT 之类 contextual model
7. 最后聚合成 firm-year regression-ready 数据

3.1 基本思想

本项目的核心不是识别“公司是否提到 AI”，而是判断公司在 MD&A 中的 AI 披露是：

- 仅仅使用了 broad, symbolic, or rhetorical AI language
- 还是披露了 firm-specific、economically meaningful 的 AI implementation 或 risk/governance 信息

因此，文本分类不能停留在关键词计数，而应在句子层面区分不同类型的 AI 语言。

3.2 AI candidate sentence extraction

首先，利用透明、可扩展的 AI seed lexicon 对 MD&A 句子进行初筛，提取所有可能与 AI 相关的 candidate sentences。AI seed lexicon 可包括：

- artificial intelligence
- AI
- machine learning
- generative AI
- large language model
- neural network
- predictive analytics
- intelligent automation
- chatbot
- computer vision

该步骤的目标是 **high recall**，即尽可能保留潜在 AI 相关句子，以便后续分类阶段进行更精细的判断。

3.3 分类体系

在 AI candidate sentences 中，建议采用如下四分类体系：

0. not meaningful AI mention

句子包含 AI 术语，但不构成经济上有意义的 AI disclosure。常见情形包括：

- broad risk list 中顺带提到 AI
- 纯标题或交叉引用
- 仅提法规名称或技术概念而无公司层面内容

1. generic AI disclosure

句子提到 AI，但仅停留在：

- broad technological trend

- strategic priority
- future opportunity
- general exploration
- high-level vision

其特点是：

- 没有具体业务 use case
- 没有实施动作
- 没有 firm-specific operational linkage
- 没有 AI-specific mechanism

2. substantive AI implementation

句子描述公司自身 AI 在产品、服务、运营流程或内部管理中的具体应用。常见特征包括：

- deploy / implement / integrate / launch / build / embed
- customer service, fraud detection, underwriting, recommendation, automation 等具体业务对象
- AI-related product or platform
- AI investment, R&D, internal tool deployment

3. substantive AI risk/governance

句子描述公司自身 AI 使用所带来的具体风险机制、控制流程或治理安排。常见特征包括：

- model review, testing, validation
- AI governance framework
- AI-specific compliance or oversight
- AI-enabled operational risk
- AI-related cybersecurity mechanism

3.4 试样基础上的修改建议

基于目前已有试样，NLP 组应重点做以下调整：

第一，不再将 **`final_disclosure_type`** 作为主要文档级变量

当前试样中的 `final_disclosure_type` 过于粗糙。一个 MD&A 中往往既可能包含 generic disclosure，也可能包含 substantive implementation 或 risk/governance disclosure。将整个文档压缩成一个单一标签，会造成严重信息损失。因此，`final_disclosure_type` 最多可作为辅助描述，不应作为主要回归解释变量。

第二，新增 **`not_meaningful_ai_mention`**

目前试样中有不少 observation 只是 broad mention 或法规标题式 AI 引用，但仍被计入 AI-related hits。这会污染 AI disclosure 的分母，降低变量的经济含义。因此，需要把“碰到 AI 词但无实质披露”的句子单独剥离。

第三，将 **substantive disclosure** 拆分为 **implementation** 与 **risk/governance**

当前试样中的 substantive hits 混合了产品与流程应用，以及 model risk / governance / cyber risk 等不同类型内容。二者的经济含义和回归解释显著不同，因此需要拆分。

第四，避免将**“行业/监管层面关于 AI 的讨论”**误判为 **firm-specific substantive disclosure**

例如，若句子仅说明监管机构关注 AI 在 underwriting, marketing, claims 等场景中的使用，而未披露公司自身的 AI 应用或治理机制，则不应仅凭出现具体业务词而归类为 substantive。

第五，对近重复 **observation** 做去重

当前试样中出现多个措辞相似但本质重复的 summary，说明原始句子或摘要层面存在重复计数风险。这会导致 substantive hit counts 被高估，因此在聚合前必须基于原始 sentence-level 数据完成去重。

identifiers

- `cik`
- `gvkey`
- `ticker`
- `company_name`
- `filing_date`
- `fiscal_year`

MD&A size controls

- `mdna_total_word_count`
- `mdna_total_sentence_count`
- `mdna_total_char_count`

AI disclosure counts

- `n_ai_candidate_sentences`
- `n_not_meaningful_ai_mentions`
- `n_generic_ai_sentences`
- `n_substantive_ai_implementation_sentences`
- `n_substantive_ai_risk_governance_sentences`
- `n_substantive_ai_total_sentences`

Intensity variables

- `ai_candidate_intensity`
- `generic_ai_intensity`
- `substantive_ai_implementation_intensity`
- `substantive_ai_risk_governance_intensity`
- `substantive_ai_total_intensity`

Share variables

- `generic_ai_share`
- `substantive_ai_share`
- `substantive_impl_share`
- `substantive_risk_share`

Net measures

- `net_substantive_minus_generic`
- `impl_minus_generic`
- `risk_minus_generic`

Dummies

- `any_generic_ai_dummy`
- `any_substantive_ai_dummy`
- `any_substantive_ai_implementation_dummy`
- `any_substantive_ai_risk_governance_dummy`

QC variables

- `n_dropped_duplicate_sentences`
- `avg_classification_confidence`

gvkey
cik
tic
conm
datadate
fyear
sic

naics
ff12_ind
ff48_ind

at
sale
ni
dlc
dltt
xrd
capx
intan
gdwl
che
ppent
ceq
prcc_f
csho
oancf
xsga
oibdp

mve
log_assets
roa
roa_oibdp
leverage
sales_growth
rd_assets
capex_assets
intangibles_assets
cash_assets
ppe_assets
goodwill_assets
ocf_assets
asset_turnover
profit_margin
tobins_q
mtb

filing_date
mdna_text_length
mdna_sentence_count
ai_sentence_count

ai_paragraph_count
ai_dummy
ai_intensity
ai_wordshare
generic_ai_dummy
substantive_ai_dummy
generic_ai_count
substantive_ai_count
generic_ai_share
substantive_ai_share
ai_usecase_dummy
ai_function_dummy
ai_product_dummy
ai_process_dummy
ai_investment_dummy
ai_risk_dummy
ai_efficiency_dummy
ai_innovation_dummy
ai_customer_dummy
ai_internal_ops_dummy

post_chatgpt
transition_2022

变量名	定义	公式 / 构造方式	数据来源	备注
gvkey	Compustat 公司唯一代码	原始字段	Compustat	主键之一
cik	SEC 公司代码	原始字段	SEC / Compustat	用来连 10-K
tic	股票代码	原始字段	Compustat	检查用
conm	公司名称	原始字段	Compustat	检查用
datadate	财务报表日期	原始字段	Compustat	年度 ending date
fyear	财年	原始字段	Compustat	回归主时间维度
sic	SIC 行业代码	原始字段	Compustat	可做 industry FE

naics	NAICS 行业代码	原始字段	Compustat	可替代 SIC
ff12_ind	Fama-French 12 行业分类	由 SIC 映射	自建	推荐保留
ff48_ind	Fama-French 48 行业分类	由 SIC 映射	自建	更细行业 FE

变量名	定义	公式 / 构造方式	数据来源	备注
at	总资产	原始字段	Compustat	size 基础变量
act	流动资产	原始字段	Compustat	liquidity 类变量可用
lct	流动负债	原始字段	Compustat	同上
lt	总负债	原始字段	Compustat	可替代 debt measures
che	现金及短期投资	原始字段	Compustat	cash holding
ppent	固定资产净额	原始字段	Compustat	tangible intensity
intan	无形资产	原始字段	Compustat	intangible intensity
ceq	普通股权益	原始字段	Compustat	book equity
seq	股东权益	原始字段	Compustat	可备用
dlc	短期债务	原始字段	Compustat	leverage
dltt	长期债务	原始字段	Compustat	leverage
sale	销售收入	原始字段	Compustat	growth 和 turnover
revt	总收入	原始字段	Compustat	有时与 sale 不同
xsga	SG&A 费用	原始字段	Compustat	管理/销售费用强度

xrd	研发费用	原始字段	Compustat	很关键
xint	利息支出	原始字段	Compustat	财务压力可用
capx	资本开支	原始字段	Compustat	你们很可能会用
prcc_f	财年末股价	原始字段	Compustat / CRSP	market value
csho	流通股数	原始字段	Compustat / CRSP	market value

变量名	定义	公式 / 构造方式	数据来源	备注
log_assets	公司规模	log(at)	自建	你现在一定会用
roa	盈利能力	ni / at	自建	baseline 推荐
roa_oibdp	经营口径盈利能力	oibdp / at	自建	robustness 候选
leverage	杠杆	(dlc + dltt) / at	自建	推荐优先

sales_growth	销售增长率	(sale_t - sale_t-1) / sale_t-1	自建	需要 lag
log_sales_growth	对数销售增长	log(sale_t) - log(sale_t-1)	自建	robustness 可用
rd_assets	研发强度	xrd / at	自建	很重要
capex_assets	资本开支强度	capx / at	自建	很重要
intangibles_assets	无形资产强度	intan / at	自建	刚问到的
cash_assets	现金持有强度	che / at	自建	建议保留
ppe_assets	固定资产强度	ppent / at	自建	可反映传统资产结构
sga_assets	SG&A 强度	xsga / at	自建	管理/营销强度
profit_margin	利润率	ni / sale	自建	建议保留
asset_turnover	资产周转率	sale / at	自建	运营效率候选
current_ratio	流动比率	act / lct	自建	稳健性控制项
book_leverage_alt	备选杠杆	lt / at	自建	robustness
loss_dummy	是否亏损	1(ni < 0)	自建	很有用
rd_missing_dummy	R&D 是否缺失	1(xrd missing)	自建	建议一定加

变量名	定义	公式 / 构造方式	数据来源	备注
`mve`	股权市值	`prcc_f * csho`	自建	Tobin's Q 必备
`tobins_q`	Tobin's Q 近似值	`(mve + at - ceq) / at`	自建	baseline DV 候选
`mtb`	市净率	`mve / ceq`	自建	robustness 常用
`ln_mve`	市值对数	`log(mve)`	自建	备选 market outcome
`future_roa_1`	下一年 ROA	`lead(roa,1)`	自建	future performance
`future_roa_2`	下两年 ROA	`lead(roa,2)`	自建	persistence
`future_sales_growth_1`	下一年销售增长	`lead(sales_growth,1)`	自建	可选
`future_ocf_assets_1`	下一年经营现金流强度	`lead(ocf_assets,1)`	自建	可选

变量名	定义	公式 / 构造方式	数据来源	备注
`filing_date`	10-K 提交日期	原始字段	SEC EDGAR	用于对齐年份
`filing_year`	提交年份	从 filing_date 提取	自建	核对用
`mdna_word_count`	MD&A 总词数	分词后计数	10-K 文本	必留
`mdna_sentence_count`	MD&A 总句数	句子切分后计数	10-K 文本	必留
`ai_sentence_count`	AI 相关句数	AI 句子数	NLP 输出	必留

ai_paragraph_count	AI 相关段落数	AI 段落数	NLP 输出	建议保留
ai_dummy	是否提到 AI	1(ai_sentence_count>0)	NLP 输出	最基础
ai_intensity	AI 披露强度	ai_sentence_count / mdna_sentence_count	自建	推荐主指标之一
ai_wordshare	AI 词汇占比	AI词数 / MD&A总词数	自建	可作 robustness
generic_ai_dummy	是否有 generic AI 披露	规则/模型输出	NLP 输出	核心
substantive_ai_dummy	是否有 substantive AI 披露	规则/模型输出	NLP 输出	核心
generic_ai_count	generic AI 句数	汇总句子级分类	NLP 输出	核心
substantive_ai_count	substantive AI 句数	汇总句子级分类	NLP 输出	核心
generic_ai_share	generic AI 占比	generic_ai_count / mdna_sentence_count	自建	推荐
substantive_ai_share	substantive AI 占比	substantive_ai_count / mdna_sentence_count	自建	推荐
substantive_cond_share	实质性 AI 占 AI 披露比重	substantive_ai_count / (generic_ai_count + substantive_ai_count)	自建	很值得加
ai_usecase_dummy	是否提具体 use case	人工规则/模型输出	NLP 输出	机制分析

ai_function_dummy	是否提具体business function	同上	NLP 输出	机制分析
ai_product_dummy	是否提 AI 产品/服务	同上	NLP 输出	机制分析
ai_process_dummy	是否提 AI 流程改造	同上	NLP 输出	机制分析
ai_investment_dummy	是否提 AI 投资/部署	同上	NLP 输出	机制分析
ai_risk_dummy	是否提 AI 风险/治理	同上	NLP 输出	机制分析
ai_efficiency_dummy	是否提降本增效	同上	NLP 输出	机制分析
ai_innovation_dummy	是否提创新/新业务	同上	NLP 输出	机制分析
ai_customer_dummy	是否提客户侧应用	同上	NLP 输出	机制分析
ai_internal_ops_dummy	是否提内部运营应用	同上	NLP 输出	机制分析
ai_specificity_score	AI 披露具体性得分	规则/模型打分	NLP 输出	可连续化
ai_actionability_score	可执行性得分	规则/模型打分	NLP 输出	可连续化
ai_context_score	语境丰富度得分	规则/模型打分	NLP 输出	可连续化
manual_check_flag	是否经过人工核验	0/1	自建	建议保留
manual_label_conflict	机器与人工是否冲突	0/1	自建	质量控制

变量名	定义	公式 / 构造方式	数据来源	备注
`industry_fe`	行业固定效应标记	由 SIC/FF12/FF48 生成	自建	回归时用
`year_fe`	年固定效应标记	由 `fyear` 生成	自建	回归时用
`firm_fe`	公司固定效应标记	由 `gvkey` 生成	自建	回归时用
`post_chatgpt`	后 ChatGPT 时期虚拟变量	`1(fyear >= 2023)`	自建	核心
`transition_2022`	2022 过渡年	`1(fyear == 2022)`	自建	可删或单独控制
`sample_main`	主样本标记	比如 2018–2021 与 2023–2025	自建	很有用
`sp500_dummy`	是否在目标样本中	`0/1`	自建	如果你们只做某样本
`industry_target_dummy`	是否属于目标行业	`0/1`	自建	如果你们按行业选样本

Regression:

1. Generic AI disclosure intensity

$$GenericAIIntensity_{it} = \frac{n_generic_ai_sentences_{it}}{mdna_total_sentence_count_{it}}$$

2. Substantive AI disclosure intensity

$$SubstantiveAIIntensity_{it} = \frac{n_substantive_ai_total_sentences_{it}}{mdna_total_sentence_count_{it}}$$

3. Substantive share

$$SubstantiveAIShare_{it} = \frac{n_substantive_ai_total_sentences_{it}}{n_generic_ai_sentences_{it} + n_substantive_ai_total_sentences_{it}}$$

4. Net substantive minus generic

$$NetSubstantiveMinusGeneric_{it} = SubstantiveAIIntensity_{it} - GenericAIIntensity_{it}$$

`GenericAIIntensity`:公司有没有在“讲 AI”
`SubstantiveAIIntensity`:公司有没有在“实质性讲 AI”
`SubstantiveAIShare`:在已经讲 AI 的公司里，实质内容占比多高
`NetSubstantiveMinusGeneric`:净信息含量更偏 substantive 还是 generic

Model Group A – RQ2

Valuation relevance

（1）Valuationit=α+β1AIIntensityit+γ′Xit+μi+λt+εit

- **ValuationitValuation_{it}**
  - **Stock price**
  - **Tobin’s Q**
  - **Market-to-book（Robutness)**
- **AIIntensityit：AI-related meaningful disclosure intensity**
- **Xit：control variable**
- **μi：firm fixed effects & Industry FE**
- **λt：year fixed effects**

4962	AMERICAN EXPRESS CO	13/2/2019	generic_ai_disclosure	0.02375
4962	AMERICAN EXPRESS CO	13/2/2020	substantive_ai_disclosure	0.02375

（2）Valuationit=α+β1GenericAIIntensityit+β2SubstantiveAIIntensityit+γ′Xit+μi+λt+εit

Hypothesis H0:

- **$\beta_1>0$, $\beta_2>0$**
- **$\beta_2-\beta_1>0$**

Market value substantive AI disclosure，Not generic AI talk

（3）$Valuation_{it}=\alpha+\beta_1 SubstantiveAIShare_{it}+\gamma' X_{it}+\mu_i+\lambda_t+\varepsilon_{it}$

（4）$Valuation_{it}=\alpha+\beta_1 NetSubstantiveMinusGenericit+\gamma' X_{it}+\mu_i+\lambda_t+\varepsilon_{it}$ ——Robutsness

Control Variables:

firm size（log assets / log market cap）

profitability（ROA / operating margin）

leverage

R&D intensity

capital expenditure intensity

sales growth

intangible intensity

year FE

industry FE

Model Group B – RQ3

Post-ChatGPT heterogeneity

（1）
$Valuation_{it}=\alpha+\beta_1 GenericAIIntensity_{it}+\beta_2 SubstantiveAIIntensity_{it}+\beta_3(GenericAIIntensity_{it}\times Post_t)+\beta_4(SubstantiveAIIntensity_{it}\times Post_t)+\gamma' X_{it}+\mu_i+\lambda_t+\varepsilon_{it}$

- **$Post_t=1$: post-ChatGPT / post-GenAI boom period，if fiscal year≥2023**

  在 **GenAI** 爆发后，市场对 **generic** 与 **substantive AI disclosure** 的定价权重是否发生了变化？

H0:

- **$\beta_4>0$**

- **$\beta_4-\beta_3>0$ (restriction test**
- **substantive AI disclosure in post period has better valuation relevance**
- **generic AI talk 不一定同步增强，甚至可能被市场视为 hype**

（2）$Valuation_{it}=\alpha+\beta_1 SubstantiveAIShare_{it}+\beta_2(SubstantiveAIShare_{it}\times Post_{t})+\gamma' X_{it}+\mu_i+\lambda_t+\varepsilon_{it}$

Model Group C – RQ3

Future outcomes / informativeness

（1）
$FutureSalesGrowth_{i,t+1}=\alpha+\beta_1 GenericAIIntensity_{it}+\beta_2 SubstantiveAIIntensity_{it}+\gamma' X_{it}+\mu_i+\lambda_t+\varepsilon_{i,t+1}$

（2）
$FutureROA_{i,t+1}=\alpha+\beta_1 GenericAIIntensity_{it}+\beta_2 SubstantiveAIIntensity_{it}+\gamma' X_{it}+\mu_i+\lambda_t+\varepsilon_{i,t+1}$

Model D(extension)
(1)$Return_{i,t+1}=\alpha+\beta_1 GenericAIIntensity_{it}+\beta_2 SubstantiveAIIntensity_{it}+\gamma' X_{it}+\lambda_t+\varepsilon_{i,t+1}$
如果 generic 更强对应短期正收益，可能更像 hype
如果 substantive 更稳定，可能更像信息

(2)$Return_{i,t+h}=\alpha+\beta_1 GenericAIIntensity_{it}+\beta_2 SubstantiveAIIntensity_{it}+\gamma' X_{it}+\lambda_t+\varepsilon_{i,t+h}$ $h=1,2,\ldots,12$
generic AI talk 会不会先被市场追捧，后面反转？
substantive AI disclosure 是否更持久、更少 reversal？